

Modelos TV^q no convexos en Restauración de Imágenes

análisis y un solucionador basado en regularización de región de confianza con convergencia superlineal

Hintermüller y Wu (2013)

MODEMAT

28 de mayo de 2026

- Motivación del modelo TV_q , con $0 < q < 1$.
- Planteamiento del modelo variacional no convexo.
- Regularización tipo Huber del término no diferenciable.
- Método Newton primal-dual regularizado.
- Resultados teóricos y numéricos.

Pregunta central

¿Cómo restaurar una imagen degradada preservando bordes y promoviendo la dispersión en el gradiente?

Datos observados

Se observa una imagen degradada

$$z = Ku + \eta,$$

donde:

- u : imagen verdadera,
- K : operador de degradación, por ejemplo blur,
- η : ruido.

Meta

Reconstruir una imagen u que:

- sea cercana a los datos z ,
- sea regular,
- conserve bordes importantes.

El modelo clásico: Variación Total

El enfoque de variación total busca resolver, en forma simplificada,

$$\min_u \frac{\lambda}{2} \|Ku - z\|_2^2 + \alpha \text{TV}(u),$$

donde


$$\text{TV}(u) = \sum_{(i,j) \in \Omega} |(\nabla u)_{ij}|.$$

Ventaja principal

La variación total penaliza el gradiente, pero permite discontinuidades: por eso preserva bordes mejor que regularizaciones cuadráticas.

Dispersión en el gradiente

En restauración de imágenes, muchas imágenes naturales son aproximadamente constantes por regiones.



Idea

Si el gradiente es cero en muchas zonas y distinto de cero solo en los bordes, entonces queremos promover sparsity de ∇u .

De ℓ_1 a ℓ_q : la idea del paper

La TV clásica usa una penalización tipo ℓ_1 sobre el gradiente.

$$\sum_i |v_i|$$

El paper propone usar una penalización no convexa:

$$\sum_i |v_i|^q, \quad 0 < q < 1.$$

Interpretación

Para $0 < q < 1$, la penalización se acerca más a contar componentes no nulas, es decir, se aproxima mejor a una idea tipo ℓ_0 .

- 1 Introduce un modelo TV_q no convexo para restauración de imágenes.
- 2 Prueba existencia de minimizador en el caso discreto.
- 3 Regulariza localmente el término no diferenciable mediante una función tipo Huber.
- 4 Propone un método Newton primal-dual semismooth.
- 5 Usa regularización basada en región de confianza para tratar Hessianos indefinidos.
- 6 Demuestra convergencia global y convergencia local superlineal hacia puntos estacionarios del problema regularizado.

- Ω : dominio discreto de píxeles.
- $u \in \mathbb{R}^{|\Omega|}$: imagen reconstruida.
- $z \in \mathbb{R}^{|\Omega|}$: datos observados.
- $K \in \mathbb{R}^{|\Omega| \times |\Omega|}$: operador de degradación.
- $\nabla u = (\nabla_x u, \nabla_y u)$: gradiente discreto.
- $\lambda_{ij} > 0$: peso de fidelidad, posiblemente dependiente del píxel.

Norma local

Para cada píxel:

$$|(\nabla u)_{ij}| = \sqrt{((\nabla_x u)_{ij})^2 + ((\nabla_y u)_{ij})^2}.$$

El problema principal en el caso discreto es:

$$\min_{u \in \mathbb{R}^{|\Omega|}} f(u) := \sum_{(i,j) \in \Omega} \left(\frac{\mu}{2} |(\nabla u)_{ij}|^2 + \frac{\alpha}{q} |(\nabla u)_{ij}|^q + \frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2 \right).$$

Parámetros

$$\alpha > 0, \quad 0 < q < 1, \quad 0 < \mu \ll \alpha.$$

Planteamiento del modelo

Fidelidad

$$\frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2$$

Obliga a que Ku se parezca a los datos observados.

TV_q

$$\frac{\alpha}{q} |(\nabla u)_{ij}|^q$$

Promueve sparsity del gradiente y preserva bordes.

Término H^1

$$\frac{\mu}{2} |(\nabla u)_{ij}|^2$$

Aporta suavidad y estabilidad adicional.

Hipótesis clave

$$\text{Ker}(\nabla) \cap \text{Ker}(K) = \{0\}.$$

Resultado

Bajo condiciones adecuadas sobre μ, α, q, λ y K , existe al menos un minimizador global del problema discreto.

Intuición

La hipótesis evita direcciones no controladas: no debe existir una imagen constante que también sea anulada por K .

No convexidad y no diferenciabilidad

Para $0 < q < 1$, la función

$$s \mapsto |s|^q$$

es no convexa y no es Lipschitz en cero.

Conjunto activo e inactivo

$$A(u) = \{(i, j) \in \Omega : |(\nabla u)_{ij}| \neq 0\}, \quad I(u) = \Omega \setminus A(u).$$

Consecuencia

La ecuación de Euler–Lagrange se debe interpretar separando píxeles activos e inactivos.

Una condición de estacionariedad se escribe como:

$$\begin{cases} -\mu\Delta u + K^\top \lambda(Ku - z) + \alpha \nabla^\top (|\nabla u|^{q-2} \nabla u) = 0, & (i,j) \in A(u), \\ \nabla u = 0, & (i,j) \in I(u). \end{cases}$$

Problema computacional

El término $|\nabla u|^{q-2}$ puede explotar cuando $|\nabla u| \rightarrow 0$.

Para hacer el problema tratable numéricamente, se suaviza localmente:

$$\varphi_\gamma(s) = \begin{cases} \frac{1}{q}|s|^q - \left(\frac{1}{q} - \frac{1}{2}\right)\gamma^q, & |s| > \gamma, \\ \frac{1}{2}\gamma^{q-2}|s|^2, & |s| \leq \gamma. \end{cases}$$

Interpretación

Cerca de cero se reemplaza $|s|^q$ por una expresión cuadrática más regular.

El problema regularizado es:

$$\min_{u \in \mathbb{R}^{|\Omega|}} f_{\gamma}(u) := \sum_{(i,j) \in \Omega} \left(\frac{\mu}{2} |(\nabla u)_{ij}|^2 + \alpha \varphi_{\gamma}(|(\nabla u)_{ij}|) + \frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2 \right).$$

Ventaja

El funcional f_{γ} es continuamente diferenciable.

La condición de primer orden del problema regularizado es:

$$\nabla f_{\gamma}(u) = -\mu\Delta u + K^{\top}\lambda(Ku - z) + \alpha\nabla^{\top}(\max(|\nabla u|, \gamma)^{q-2}\nabla u) = 0.$$

Idea clave

La función $\max(|\nabla u|, \gamma)$ evita dividir por cantidades cercanas a cero.

Resultado del paper

Si u_k son puntos estacionarios del problema Huberizado y $\gamma_k \rightarrow 0^+$, entonces existe una subsucesión que converge a un punto que satisface las ecuaciones de Euler–Lagrange del problema original.

Mensaje para la exposición

La Huberización no es solo un truco numérico: está conectada con el problema original cuando el parámetro γ se hace pequeño.

Se introduce una variable dual p asociada al gradiente:

$$\begin{cases} -\mu\Delta u + K^\top \lambda(Ku - z) + \alpha \nabla^\top p = 0, \\ \max(|\nabla u|, \gamma)^{2-q} p = \nabla u. \end{cases}$$

Ventaja

Esta formulación separa el equilibrio primal de la relación no lineal entre p y ∇u .

El objetivo es resolver el sistema no lineal primal-dual mediante un método de Newton generalizado.

Motivación

Los métodos Newton pueden ser muy rápidos localmente, pero aquí aparecen dos dificultades:

- no convexidad del funcional,
- posible indefinitud del Hessiano generalizado.

Estrategia del paper

Combinar Newton semismooth con reweighting y regularización tipo región de confianza.

Dado un iterado u^k , se define

$$m^k = \text{máx}(|\nabla u^k|, \gamma),$$

y el peso

$$w^k = (m^k)^{q+r-2}, \quad 0 \leq r \leq 2 - q.$$

La ecuación reponderada queda:

$$-\mu \Delta u + K^\top \lambda(Ku - z) + \alpha \nabla^\top \left(w^k \text{máx}(|\nabla u|, \gamma)^{-r} \nabla u \right) = 0.$$

Después de linealizar y eliminar la variable dual, se obtiene un sistema de la forma:

$$\tilde{H}_k(r) \delta u^{k+1} = -g^k,$$

donde

$$g^k = \nabla f_\gamma(u^k).$$

Lectura computacional

En cada iteración se busca una dirección δu^{k+1} que reduzca el residuo de estacionariedad.

El problema del Hessiano indefinido

En problemas convexos, el Hessiano suele ser semidefinido positivo.

En este paper, por $0 < q < 1$:

- el funcional es no convexo,
- el Hessiano generalizado puede no ser positivo definido,
- una dirección de Newton puede no ser de descenso.

Consecuencia

Hay que estabilizar el sistema de Newton.

El paper interpreta el reweighting como una regularización del Hessiano:

$$(H_k + \beta_k R_k) \delta u^{k+1} = -g^k.$$

Rol de β_k

- Si β_k es grande, el sistema es más estable.
- Si $\beta_k \rightarrow 0$, se recupera el comportamiento de Newton puro.

Idea clave

Regularizar lejos de la solución, pero dejar que la regularización desaparezca cerca de la solución.

Se usa un modelo cuadrático local:

$$h_k(d) = f_\gamma(u^k) + (g^k)^\top d + \frac{1}{2} d^\top H_k^+ d.$$

La dirección se controla mediante una restricción tipo región de confianza:

$$\frac{1}{2} d^\top R_{k,\epsilon}^+ d \leq \frac{1}{2} \sigma_k^2.$$

Propósito

Elegir adaptativamente la cantidad de regularización necesaria para obtener una dirección confiable.

Algoritmo adaptativamente regularizado

- 1 Inicializar $u^0, p^0, \beta_0, \sigma_0$.
- 2 Construir $H_k^+, R_{k,\epsilon}^+$ y g^k .
- 3 Resolver

$$(H_k^+ + \beta_k R_{k,\epsilon}^+) d^k = -g^k.$$

- 4 Verificar si d^k es dirección de descenso.
- 5 Actualizar β_k y σ_k con criterio de región de confianza.
- 6 Hacer búsqueda lineal de Wolfe–Powell.
- 7 Actualizar $u^{k+1} = u^k + a_k d^k$.

Resultado

Bajo las condiciones del algoritmo y usando búsqueda lineal de Wolfe–Powell,

$$\lim_{k \rightarrow \infty} \nabla f_{\gamma}(u^k) = 0.$$

Interpretación

El algoritmo no necesariamente encuentra un mínimo global, porque el problema es no convexo, pero sí converge hacia un punto estacionario del problema Huberizado.

Resultado local

Si la sucesión converge a un punto estacionario adecuado y los elementos del B-Hessiano son definidos positivos, entonces:

$$\left\| u^{k+1} - u^* \right\| = o \left(\left\| u^k - u^* \right\| \right).$$

Idea central

La regularización R se apaga cerca de la solución:

$$\beta_k \rightarrow 0.$$

Así se recupera la velocidad rápida de Newton.

Los autores prueban el método en problemas de:

- denoising,
- deblurring,
- comparación con TV convexa,
- sensibilidad al valor inicial.

Parámetros típicos reportados

En varios experimentos se usa, por ejemplo,

$$q = 0,75, \quad \mu = 10^{-4}\alpha, \quad \gamma = 0,1.$$

Plantilla para mostrar resultados visuales

Original

Ruidosa

TV clásica

TV_q

Mensaje que se debe enfatizar

El modelo TV_q tiende a preservar mejor los bordes y a promover mayor sparsity del gradiente que la TV convexa.

Conclusiones

- TV_q , con $0 < q < 1$, es una alternativa no convexa a la TV clásica.
- La Huberización permite tratar numéricamente la no diferenciabilidad cerca de cero.
- El método Newton primal-dual es estabilizado mediante regularización R y región de confianza.
- El esquema combina convergencia global con convergencia local superlineal.
- Para tesis sobre TV cuasinormada, este paper es una referencia central.

Referencia: M. Hintermüller y T. Wu (2013). *Nonconvex TV_q -Models in Image Restoration: Analysis and a Trust-Region Regularization-Based Superlinearly Convergent Solver*. SIAM Journal on Imaging Sciences, 6(3), 1385–1415.