

Modelos TV^q no convexos en Restauración de Imágenes
análisis y un solucionador basado en regularización de región de confianza con
convergencia superlineal

Hintermüller y Wu (2013)

MODEMAT

28 de mayo de 2026

- Motivación del modelo TV_q , con $0 < q < 1$.
- Planteamiento del modelo variacional no convexo.
- Regularización tipo Huber del término no diferenciable.
- Método Newton primal-dual regularizado.
- Resultados teóricos y numéricos.

Objetivo principal del artículo:

- 1 Expandir la capacidad de los algoritmos para recuperar imágenes usando la norma ℓ_q .
- 2 Lograr robustez ante el ruido y convergencia superlineal local.

- Ω : dominio discreto de píxeles.
- $u \in \mathbb{R}^{|\Omega|}$: imagen reconstruida.
- $z \in \mathbb{R}^{|\Omega|}$: datos observados.
- $K \in \mathbb{R}^{|\Omega| \times |\Omega|}$: operador de degradación.
- $\nabla u = (\nabla_x u, \nabla_y u)$: gradiente discreto.
- $\lambda_{ij} > 0$: coeficiente de fidelidad.

Para cada píxel

$$|(\nabla u)_{ij}| = \sqrt{((\nabla_x u)_{ij})^2 + ((\nabla_y u)_{ij})^2}.$$

El problema principal en el caso discreto es:

$$\min_{u \in \mathbb{R}^{|\Omega|}} f(u) := \sum_{(i,j) \in \Omega} \left(\frac{\mu}{2} |(\nabla u)_{ij}|^2 + \frac{\alpha}{q} |(\nabla u)_{ij}|^q + \frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2 \right). \quad (1)$$

Parámetros

$\alpha > 0$, $q \in (0, 1)$, $0 < \mu \ll \alpha$.

Fidelidad

$$\frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2$$

Obliga a que Ku se parezca a los datos observados.

TV_q

$$\frac{\alpha}{q} |(\nabla u)_{ij}|^q$$

Promueve dispersión del gradiente y preserva bordes.

Término extra

$$\frac{\mu}{2} |(\nabla u)_{ij}|^2$$

Aporta suavidad y estabilidad adicional.

Teorema 1

Supongamos que $\mu \geq 0$, $\alpha > 0$, $q > 0$, $\lambda_{ij} > 0$ para todo $(i, j) \in \Omega$ y

$$\text{Ker} \nabla \cap \text{Ker} K = \{0\}.$$

Entonces existe un minimizador global para el problema variacional (??).

Idea de la Demostración:

- 1 Dado que f es acotada inferiormente, basta probar que f es coerciva (tiende a $+\infty$ cuando $\|u\|$ tiende a $+\infty$), puesto que si f es coerciva y continua, entonces existe un minimizador.
- 2 La coercividad de f se prueba por contradicción, de modo que se encuentra un elemento no nulo en la intersección de $\text{Ker}(\nabla)$ y $\text{Ker}(K)$. Como esto no es posible de acuerdo a la hipótesis, entonces f es coerciva.

Para caracterizar la solución óptima u , se definen los conjuntos activo e inactivo de la siguiente forma:

$$\mathcal{A}(u) := \{(i, j) \in \Omega : |(\nabla u)_{ij}| \neq 0\}, \quad \mathcal{I}(u) := \Omega \setminus \mathcal{A}(u).$$

Como f es no diferenciable en $\mathcal{I}(u)$, la ecuación de Euler-Lagrange para caracterizar un punto estacionario se plantea como sigue


$$\begin{cases} -\mu \Delta u + K^T \lambda (Ku - z) + \alpha \nabla^T (|\nabla u|^{q-2} \nabla u) = 0 & \text{si } (i, j) \in \mathcal{A}(u) \\ \nabla u = 0 & \text{si } (i, j) \in \mathcal{I}(u). \end{cases} \quad (2)$$

Dado que f no es convexa, la solución de (2) en general no es única.

Regularización mediante una función de Huber φ_γ :

$$\varphi_\gamma(s) = \begin{cases} \frac{1}{q}|s|^q - \left(\frac{1}{q} - \frac{1}{2}\right)\gamma^q & \text{si } |s| > \gamma, \\ \frac{1}{2}\gamma^{q-2}|s|^2 & \text{si } |s| \leq \gamma, \end{cases}$$

con $\gamma > 0$ pequeño.



De este modo obtenemos el problema regularizado que aproxima al problema original, dado de la siguiente forma

$$\min_{u \in \mathbb{R}^{|\Omega|}} f_\gamma(u) := \sum_{(i,j) \in \Omega} \left(\frac{\mu}{2} |(\nabla u)_{ij}|^2 + \alpha \varphi_\gamma(|(\nabla u)_{ij}|) + \frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2 \right). \quad (3)$$

Dado que f_γ es continuamente diferenciable, la ecuación de Euler-Lagrange (condición de primer orden del problema regularizado) está dada por

$$\nabla f_\gamma(u) = -\mu \Delta u + \mathbb{K}^T \lambda (Ku - z) + \alpha \nabla^T (\max(|\nabla u|, \gamma)^{q-2} \nabla u) \quad (4)$$

Ventaja

La función $\max(|\nabla u|, \gamma)$ evita dividir por cantidades cercanas a cero.

¿Qué sucede si $\gamma \rightarrow 0^+$?

Teorema 2

Sean válidos los supuestos del Teorema 1. Además supongamos que (u^k) es una sucesión uniformemente acotada, donde cada u^k es un punto estacionario del problema (3) que satisface (4). Entonces cuando $\gamma \rightarrow 0^+$, existe una subsucesión de (u^k) que converge a algún $u^* \in \mathbb{R}^{|\Omega|}$, el cual satisface la ecuación de Euler-Lagrange original (2)

Reformulamos las condiciones de primer orden del problema regularizado (4), que también se muestran a continuación

$$\nabla f_\gamma(u) = -\mu \Delta u + \mathbb{K}^\top \lambda(Ku - z) + \alpha \nabla^\top (\max(|\nabla u|, \gamma)^{q-2} \nabla u), \quad (5)$$

introduciendo una variable dual $\vec{p} \in (\mathbb{R}^{|\Omega|})^2$, tal que

$$\begin{cases} -\mu \Delta u + K^\top \lambda(Ku - z) + \alpha \nabla^\top \vec{p} = 0, \\ \max(|\nabla u|, \gamma)^{2-q} \vec{p} = \nabla u. \end{cases} \quad (6)$$

El objetivo es resolver el sistema no lineal primal-dual mediante un método de Newton generalizado.

Motivación

Los métodos Newton pueden ser muy rápidos localmente, pero aquí aparecen dos dificultades:

- no convexidad del funcional,
- Hessiano generalizado indefinido.

Estrategia del paper

Combinar Newton semismooth con repoderación y regularización tipo región de confianza.

Dado u^k , se define el peso como

$$w^k = (\max(|\nabla u^k|, \gamma))^{q+r-2}, \quad 0 \leq r \leq 2 - q.$$

La ecuación reponderada queda:

$$-\mu \Delta u + K^\top \lambda(Ku - z) + \alpha \nabla^\top \left(w^k \max(|\nabla u|, \gamma)^{-r} \nabla u \right) = 0.$$

Luego se introduce la variable dual reponderada

$$\vec{p} = w^k \max(|\nabla u|, \gamma)^{-r} \nabla u.$$

Entonces (6) se escribe como

$$\begin{cases} -\mu \Delta u + K^\top \lambda(Ku - z) + \alpha \nabla^\top \vec{p} = 0, \\ (w^k)^{-1} \max(|\nabla u|, \gamma)^r \vec{p} = \nabla u. \end{cases} \quad (7)$$

Después de aplicar una linealización generalizada a (7), se obtiene un sistema de la forma:

$$\tilde{H}^k(r) \delta u^{k+1} = -g^k,$$

donde

$$g^k = \nabla f_\gamma(u^k).$$

Lectura computacional

En cada iteración se busca una dirección δu^{k+1} que reduzca el residuo de estacionariedad.

En problemas convexos, el Hessiano suele ser semidefinido positivo.

En este paper, ya que $0 < q < 1$:

- el funcional es no convexo,
- el Hessiano generalizado puede no ser positivo definido,
- una dirección de Newton puede no ser de descenso.

La reponderación se interpreta como una regularización del Hessiano, denominada R -regularización, de modo que el sistema de Newton se escribe

$$(H_k + \beta_k R_k) \delta u^{k+1} = -g^k.$$

Rol de β_k

- Si β_k es grande, el sistema es más estable.
- Si $\beta_k \rightarrow 0$, se recupera el comportamiento de Newton puro.

La versión R -regularizada del método de Newton generalizado con β fijo es linealmente convergente. Sin embargo, se propone una nueva versión adaptativamente R -regularizada del método de Newton generalizado que alcanza convergencia local superlineal. Para ello se requiere una estrategia de actualización adecuada para $\beta > 0$. Por lo que se propone un esquema de tipo región de confianza. Dado un u^k , se modela a f_γ localmente mediante una función cuadrática $h : \mathbb{R}^{|\Omega|} \rightarrow \mathbb{R}$ con

$$h^k(d) = f_\gamma(u^k) + (g^k)^\top d + \frac{1}{2} d^\top H_+^k d.$$

La dirección se controla mediante una restricción tipo región de confianza:

$$\frac{1}{2} d^\top R_{k,\varepsilon}^+ d \leq \frac{1}{2} \sigma_k^2.$$

Algoritmo 3.6: Método de Newton adaptativamente regularizado

Require: input parameters $1 - q \leq \beta_{\max} \leq 2 - q$, $c > 0$, $0 < \rho_1 \leq \rho_2 < 1$, $0 < \kappa_1 < 1 < \kappa_2$, $0 < \varepsilon \ll \alpha$, $0 < \epsilon_d \leq \bar{\epsilon}_d$, $0 < \tau_1 < 1/2$, $\tau_1 < \tau_2 < 1$.

- 1: Initialize $(u^0, \bar{p}^0)$, the regularization scalar $\beta^0 \geq 0$, and the trust-region radius $\sigma^0 > 0$. Set $k := 0$.
- 2: repeat {outer loop}
- 3: Generate $H_{+, \varepsilon}^k$, $R_{+, \varepsilon}^k$, and g^k .
- 4: repeat {inner loop}
- 5: Solve $(H_{+, \varepsilon}^k + \beta^k R_{+, \varepsilon}^k) d^k = -g^k$ for d^k .
- 6: if $-(g^k)^\top d^k / (\|g^k\| \|d^k\|) < \epsilon_d$ then Set $\beta^k := \beta_{\max}$ and return to step 5.
- 7: end if
- 8: if $\beta^k = \beta_{\max}$ and $(d^k)^\top R_{+, \varepsilon}^k d^k > (\sigma^k)^2$ then
- 9: Set $\sigma^k := \sqrt{(d^k)^\top R_{+, \varepsilon}^k d^k}$ and go to step 15.
- 10: end if
- 11: Update $\beta^k := \beta^k + ((d^k)^\top R_{+, \varepsilon}^k d^k - (\sigma^k)^2) / (2c)$.
- 12: Project β^k onto $[0, \beta_{\max}]$; i.e., set $\beta^k := \max(\min(\beta^k, \beta_{\max}), 0)$.
- 13: until the stopping criterion for the inner loop is fulfilled.
- 14: Evaluate $\rho^k := [f_\gamma(u^k) - f_\gamma(u^k + d^k)] / [f_\gamma(u^k) - (f_\gamma(u^k) + (g^k)^\top d^k + \frac{1}{2}(d^k)^\top H_{+, \varepsilon}^k d^k)]$.
- 15: if $\rho^k < \rho_1$ then Set $\sigma^{k+1} := \kappa_1 \sigma^k$.
- 16: else if $\rho^k > \rho_2$ then Set $\sigma^{k+1} := \kappa_2 \sigma^k$.
- 17: else $\sigma^{k+1} := \sigma^k$.
- 18: end if
- 19: Determine step size a^k along d^k such that $u^{k+1} = u^k + a^k d^k$ satisfies the Wolfe–Powell conditions:
 (3.35) $f_\gamma(u^{k+1}) \leq f_\gamma(u^k) + \tau_1 a^k \nabla f_\gamma(u^k)^\top d^k$ and (3.36) $\nabla f_\gamma(u^{k+1})^\top d^k \geq \tau_2 \nabla f_\gamma(u^k)^\top d^k$.
- 20: Set $\delta u^{k+1} := d^k$ and compute $\delta \bar{p}^{k+1}$ via (3.9). Update $u^{k+1} := u^k + a^k \delta u^{k+1}$ and $\bar{p}^{k+1} := \bar{p}^k + a^k \delta \bar{p}^{k+1}$.
- 21: Set $\beta^{k+1} := \beta^k$ and $k := k + 1$.
- 22: until the stopping criterion for the outer loop is fulfilled.

Resultado

Bajo las condiciones del algoritmo y usando búsqueda lineal de Wolfe–Powell,

$$\lim_{k \rightarrow \infty} \nabla \|f_\gamma(u^k)\| = 0.$$

Interpretación

El algoritmo no necesariamente encuentra un mínimo global, porque el problema es no convexo, pero sí converge hacia un punto estacionario del problema Huberizado.

Resultado local

Si la sucesión converge a un punto estacionario adecuado y los elementos del B-Hessiano son definidos positivos, entonces:

$$\left\| u^{k+1} - u^* \right\| = o \left(\left\| u^k - u^* \right\| \right) .$$

Los autores muestran los resultados obtenidos con su método de Newton primal-dual. Ω denota el dominio de píxeles de tamaño $m \times n$, es decir,

$$\Omega = \{(i, j) \in \mathbb{Z}^2 : 1 \leq i \leq m, 1 \leq j \leq n\}.$$

Se discretiza el operador gradiente mediante

$$(\nabla u)_{i,j} = \left(\frac{u_{i+1,j} - u_{i,j}}{\omega}, \frac{u_{i,j+1} - u_{i,j}}{\omega} \right)$$

con $\omega = \sqrt{1/|\Omega|}$. Se fija $u_{i,j} = 0$ siempre que $(i, j) \notin \Omega$. A menos que se especifique lo contrario y se utilizan los siguientes parámetros: $q = 0,75$, $\mu = 10^{-4}\alpha$, $\gamma = 0,1$.

Imagen de los dos círculos. En este experimento el tamaño de la imagen es de 64×64 píxeles, la imagen original se contamina con ruido gaussiano de media cero y desviación estándar 0.1. Para este ejemplo $\alpha = 2 \times 10^{-3}$ y $\mu = 0$.

Dependencia del punto inicial

Punto inicial	Función objetivo	PSNR	CPU (seg)
$u^0 = z$	42.0354	30.2395	3.06
$u^0 = 0$	42.0385	30.2438	3.02
Random u^0	42.0373	30.2048	3.19

Dependencia del valor del parámetro de regularización (Parámetro de Huber)

Parámetro de Huber γ	1e1	1e0	1e-1	1e-2	1e-3
# Newton iter.	5	28	37	40	43
PSNR	25.3644	29.7011	30.12	30.1489	30.1489

Observación.

Vemos que conforme el valor del parámetro de Huber disminuye, el costo computacional (iteraciones) aumenta.

Imagen Shepp-Logan phantom En este experimento el tamaño de la imagen es de 256×256 píxeles, la imagen original se contamina con ruido gaussiano de media cero y desviación estándar 0.05. Para este ejemplo $\mu = 0$. En este experimento se resuelve el problema para $q = 1, 0,75, 0,5$ y $0,25$. Para cada q , el parámetro α se escoge manualmente de modo que se obtenga el mejor valor de PSNR.

q	α
1	3×10^{-4}
0.75	4×10^{-4}
0.5	6×10^{-4}
0.25	1.2×10^{-3}

q	PSNR	$ \mathcal{A}_\gamma(\hat{u}_q) / \Omega $	$f_{\gamma,q}(\hat{u}_q)$	$f_{\gamma,q}(\hat{u}_1)$
1	37.5709	0.196	—	—
0.75	41.0039	0.0578	134.3021	137.6719
0.5	41.0191	0.0531	116.6721	125.6655
0.25	39.9259	0.0503	113.9953	133.6758

Observación.

- $\hat{u}_q$ es la imagen obtenida con el modelo TV_q.
- $\hat{u}_1$ es la imagen obtenida con el modelo TV.
- $|\mathcal{A}_\gamma(\hat{u}_q)|/|\Omega|$ mide la dispersión del gradiente.

Además se considera lo siguiente:

- El subproblema de región de confianza (3.18)–(3.19) se resuelve solo de forma aproximada. De hecho, a partir de su experiencia numérica, una sola iteración interna parece ser suficiente en la práctica para el Algoritmo 3.6. El bucle externo se finaliza una vez que la norma del residuo $\|\nabla f_\gamma(u^k)\|$ (ver fórmula (2.5)) se ha reducido en un factor de 10^{-7} .
- En el paso 5 del Algoritmo 3.6, se requiere resolver un sistema de Newton R -regularizado. En un problema de eliminación de ruido (es decir, cuando $K = I$), el sistema lineal se puede resolver eficientemente mediante una factorización de Cholesky dispersa. Para problemas donde K es una matriz densa o ni siquiera se formula explícitamente como una matriz, utilizamos el método del gradiente conjugado con una tolerancia del residuo de 0,05.
- Todos los experimentos se realizaron bajo MATLAB R2009b en una laptop Intel Core de 2.66 GHz con 4 GB de memoria RAM.

Original

Ruidosa

TV clásica

TV_q

Mensaje que se debe enfatizar

El modelo TV_q tiende a preservar mejor los bordes y a promover mayor sparsity del gradiente que la TV convexa.

- 1 Introduce un modelo TV_q no convexo para restauración de imágenes.
- 2 Prueba existencia de minimizador en el caso discreto.
- 3 Regulariza localmente el término no diferenciable mediante una función tipo Huber.
- 4 Propone un método Newton primal-dual semismooth.
- 5 Usa regularización basada en región de confianza para tratar Hessianos indefinidos.
- 6 Demuestra convergencia global y convergencia local superlineal hacia puntos estacionarios del problema regularizado.

3. Motivación de la Regularización No Convexa ℓ_q

Para evitar el *staircasing*, la literatura moderna recurre a las pseudo-normas ℓ_q con $0 < q < 1$:

- **Sparsity:** La penalización $|x|^q$ para $q < 1$ se aproxima fuertemente a la norma ℓ_0 (recuperación exacta de bordes).
- **Preservación de Discontinuidades:** Castiga menos los saltos grandes y penaliza fuertemente las variaciones pequeñas cerca del origen.
- **Precisión Matemática:** El modelo se adapta mejor a las estadísticas estadísticas reales de las imágenes naturales (distribuciones de cola pesada).

Conclusiones

- TV_q , con $0 < q < 1$, es una alternativa no convexa a la TV clásica.
- La Huberización permite tratar numéricamente la no diferenciabilidad cerca de cero.
- El método Newton primal-dual es estabilizado mediante regularización R y región de confianza.
- El esquema combina convergencia global con convergencia local superlineal.
- Para tesis sobre TV cuasinormada, este paper es una referencia central.

Referencia: M. Hintermüller y T. Wu (2013). *Nonconvex TV_q-Models in Image Restoration: Analysis and a Trust-Region Regularization-Based Superlinearly Convergent Solver*. SIAM Journal on Imaging Sciences, 6(3), 1385–1415.