

Modelos TV^q no convexos en Restauración de Imágenes
análisis y un solucionador basado en regularización de región de confianza con
convergencia superlineal

Hintermüller y Wu (2013)

MODEMAT

28 de mayo de 2026

Objetivo principal del artículo:

- 1 Expandir la capacidad de los algoritmos para recuperar imágenes usando la norma ℓ_q .
- 2 Lograr robustez ante el ruido y convergencia superlineal local.

- Ω : dominio discreto de píxeles.
- $u \in \mathbb{R}^{|\Omega|}$: imagen reconstruida.
- $z \in \mathbb{R}^{|\Omega|}$: datos observados.
- $K \in \mathbb{R}^{|\Omega| \times |\Omega|}$: operador de degradación.
- $\nabla u = (\nabla_x u, \nabla_y u)$: gradiente discreto.
- $\Delta = -\nabla_x^T \nabla_x - \nabla_y^T \nabla_y$: Laplaciano discreto.
- $\lambda_{ij} > 0$: coeficiente de fidelidad.

Para cada píxel

$$|(\nabla u)_{ij}| = \sqrt{((\nabla_x u)_{ij})^2 + ((\nabla_y u)_{ij})^2}.$$

El problema es:

$$\min_{u \in \mathbb{R}^{|\Omega|}} f(u) := \sum_{(i,j) \in \Omega} \left(\frac{\mu}{2} |(\nabla u)_{ij}|^2 + \frac{\alpha}{q} |(\nabla u)_{ij}|^q + \frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2 \right). \quad (1)$$

Parámetros

$\alpha > 0$, $q \in (0, 1)$, $0 < \mu \ll \alpha$.

Fidelidad

$$\frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2$$

Obliga a que Ku se parezca a los datos observados.

TV_q

$$\frac{\alpha}{q} |(\nabla u)_{ij}|^q$$

Promueve dispersión del gradiente y preserva bordes.

Término extra

$$\frac{\mu}{2} |(\nabla u)_{ij}|^2$$

Aporta suavidad y estabilidad adicional.

Teorema 1

Supongamos que $\mu \geq 0$, $\alpha > 0$, $q > 0$, $\lambda_{ij} > 0$ para todo $(i, j) \in \Omega$ y

$$\text{Ker} \nabla \cap \text{Ker} K = \{0\}.$$

Entonces existe un minimizador global para el problema variacional (1).

Idea de la Demostración:

- 1 Dado que f es acotada inferiormente, basta probar que f es coerciva (tiende a $+\infty$ cuando $\|u\|$ tiende a $+\infty$), puesto que si f es coerciva y continua, entonces existe un minimizador.
- 2 La coercividad de f se prueba por contradicción, de modo que se encuentra un elemento no nulo en la intersección de $\text{Ker}(\nabla)$ y $\text{Ker}(K)$. Como esto no es posible de acuerdo a la hipótesis, entonces f es coerciva.

Para caracterizar la solución óptima u , se definen los conjuntos activo e inactivo de la siguiente forma:

$$\mathcal{A}(u) := \{(i, j) \in \Omega : |(\nabla u)_{ij}| \neq 0\}, \quad \mathcal{I}(u) := \Omega \setminus \mathcal{A}(u).$$

Como f es no diferenciable en $\mathcal{I}(u)$, la ecuación de Euler-Lagrange para caracterizar un punto estacionario se plantea como sigue


$$\begin{cases} -\mu \Delta u + K^T \lambda (Ku - z) + \alpha \nabla^T (|\nabla u|^{q-2} \nabla u) = 0 & \text{si } (i, j) \in \mathcal{A}(u) \\ \nabla u = 0 & \text{si } (i, j) \in \mathcal{I}(u). \end{cases} \quad (2)$$

Dado que f no es convexa, la solución de (2) en general no es única.

Regularización mediante una función de Huber φ_γ :

$$\varphi_\gamma(s) = \begin{cases} \frac{1}{q}|s|^q - \left(\frac{1}{q} - \frac{1}{2}\right)\gamma^q & \text{si } |s| > \gamma, \\ \frac{1}{2}\gamma^{q-2}|s|^2 & \text{si } |s| \leq \gamma, \end{cases}$$

con $\gamma > 0$ pequeño.



De este modo obtenemos el problema regularizado que aproxima al problema original, dado de la siguiente forma

$$\min_{u \in \mathbb{R}^{|\Omega|}} f_\gamma(u) := \sum_{(i,j) \in \Omega} \left(\frac{\mu}{2} |(\nabla u)_{ij}|^2 + \alpha \varphi_\gamma(|(\nabla u)_{ij}|) + \frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2 \right). \quad (3)$$

Dado que f_γ es continuamente diferenciable, la ecuación de Euler-Lagrange (condición de primer orden del problema regularizado) está dada por

$$\nabla f_\gamma(u) = -\mu \Delta u + \mathbb{K}^T \lambda (Ku - z) + \alpha \nabla^T (\max(|\nabla u|, \gamma)^{q-2} \nabla u) = 0. \quad (4)$$

Ventaja

La función $\max(|\nabla u|, \gamma)$ evita dividir por cantidades cercanas a cero.

¿Qué sucede si $\gamma \rightarrow 0^+$?

Teorema 2

Sean válidos los supuestos del Teorema 1. Además supongamos que (u^k) es una sucesión uniformemente acotada, donde cada u^k es un punto estacionario del problema (3) que satisface (4). Entonces cuando $\gamma \rightarrow 0^+$, existe una subsucesión de (u^k) que converge a algún $u^* \in \mathbb{R}^{|\Omega|}$, el cual satisface la ecuación de Euler-Lagrange original (2).

Reformulamos las condiciones de primer orden del problema regularizado (4), que también se muestran a continuación

$$\nabla f_\gamma(u) = -\mu \Delta u + \mathbb{K}^\top \lambda(Ku - z) + \alpha \nabla^\top (\max(|\nabla u|, \gamma)^{q-2} \nabla u), \quad (5)$$

introduciendo una variable dual $\vec{p} \in (\mathbb{R}^{|\Omega|})^2$, tal que

$$\begin{cases} -\mu \Delta u + K^\top \lambda(Ku - z) + \alpha \nabla^\top \vec{p} = 0, \\ \max(|\nabla u|, \gamma)^{2-q} \vec{p} = \nabla u. \end{cases} \quad (6)$$

El objetivo es resolver el sistema no lineal primal-dual mediante un método de Newton generalizado.

Motivación

Los métodos Newton pueden ser muy rápidos localmente, pero aquí aparecen dos dificultades:

- no convexidad del funcional,
- Hessiano generalizado indefinido.

Estrategia del paper

Combinar Newton semismooth con repoderación y regularización tipo región de confianza.

Dado u^k , se define el peso como

$$w^k = (\max(|\nabla u^k|, \gamma))^{q+r-2}, \quad 0 \leq r \leq 2 - q.$$

La ecuación reponderada queda:

$$-\mu \Delta u + K^\top \lambda(Ku - z) + \alpha \nabla^\top \left(w^k \max(|\nabla u|, \gamma)^{-r} \nabla u \right) = 0.$$

Luego se introduce la variable dual reponderada

$$\vec{p} = w^k \max(|\nabla u|, \gamma)^{-r} \nabla u.$$

Entonces (6) se escribe como

$$\begin{cases} -\mu \Delta u + K^\top \lambda(Ku - z) + \alpha \nabla^\top \vec{p} = 0, \\ (w^k)^{-1} \max(|\nabla u|, \gamma)^r \vec{p} = \nabla u. \end{cases} \quad (7)$$

Después de aplicar una linealización generalizada a (7), se obtiene un sistema de la forma:

$$\tilde{H}^k(r) \delta u^{k+1} = -g^k,$$

donde

$$g^k = \nabla f_\gamma(u^k).$$

Lectura computacional

En cada iteración se busca una dirección δu^{k+1} que reduzca el residuo de estacionariedad.

En problemas convexos, el Hessiano suele ser semidefinido positivo.

En este paper, ya que $0 < q < 1$:

- el funcional es no convexo,
- el Hessiano generalizado puede no ser positivo definido,
- una dirección de Newton puede no ser de descenso.

La reponderación se interpreta como una regularización del Hessiano, denominada R -regularización, de modo que el sistema de Newton se escribe

$$(H^k + \beta^k R^k) \delta u^{k+1} = -g^k,$$

donde $H^k := \tilde{H}^k(2 - q)$ es el B-Hessiano en el método de Newton primal-dual sin reponderación, $\beta = \beta^k = 2 - q - r$ y r el parámetro de ponderación.

Rol de β_k

- Si β_k es grande, el sistema es más estable.
- Si $\beta_k \rightarrow 0$, se recupera el comportamiento de Newton puro.

La versión R -regularizada del método de Newton generalizado con β fijo es linealmente convergente.

Sin embargo, se propone una nueva versión adaptativamente R -regularizada del método de Newton generalizado que alcanza convergencia local superlineal.

Para ello se requiere una estrategia de actualización adecuada para $\beta > 0$. Por lo que se propone un esquema de tipo región de confianza. Dado un u^k , se modela a f_γ localmente mediante una función cuadrática $h : \mathbb{R}^{|\Omega|} \rightarrow \mathbb{R}$ con

$$h^k(d) = f_\gamma(u^k) + (g^k)^\top d + \frac{1}{2} d^\top H_+^k d.$$

La dirección d es tal que

$$\frac{1}{2} d^\top R_{+, \epsilon}^k d \leq \frac{1}{2} \sigma_k^2,$$

donde R_+ es una versión simetrizada del operador de regularización R^k , $R_{+, \epsilon}^k := R_+^k + \epsilon I$, con un parámetro arbitrario de regularización fijo $0 < \epsilon \ll \alpha$ y $\sigma^k > 0$ representa el radio de la región de confianza.

Algoritmo 3.6: Método de Newton adaptativamente regularizado

Require: input parameters $1 - q \leq \beta_{\max} \leq 2 - q$, $c > 0$, $0 < \rho_1 \leq \rho_2 < 1$, $0 < \kappa_1 < 1 < \kappa_2$, $0 < \varepsilon \ll \alpha$, $0 < \epsilon_d \leq \bar{\epsilon}_d$, $0 < \tau_1 < 1/2$, $\tau_1 < \tau_2 < 1$.

- 1: Initialize $(u^0, \bar{p}^0)$, the regularization scalar $\beta^0 \geq 0$, and the trust-region radius $\sigma^0 > 0$. Set $k := 0$.
- 2: repeat {outer loop}
- 3: Generate $H_{+, \varepsilon}^k$, $R_{+, \varepsilon}^k$, and g^k .
- 4: repeat {inner loop}
- 5: Solve $(H_{+, \varepsilon}^k + \beta^k R_{+, \varepsilon}^k) d^k = -g^k$ for d^k .
- 6: if $-(g^k)^\top d^k / (\|g^k\| \|d^k\|) < \epsilon_d$ then Set $\beta^k := \beta_{\max}$ and return to step 5.
- 7: end if
- 8: if $\beta^k = \beta_{\max}$ and $(d^k)^\top R_{+, \varepsilon}^k d^k > (\sigma^k)^2$ then
- 9: Set $\sigma^k := \sqrt{(d^k)^\top R_{+, \varepsilon}^k d^k}$ and go to step 15.
- 10: end if
- 11: Update $\beta^k := \beta^k + ((d^k)^\top R_{+, \varepsilon}^k d^k - (\sigma^k)^2) / (2c)$.
- 12: Project β^k onto $[0, \beta_{\max}]$; i.e., set $\beta^k := \max(\min(\beta^k, \beta_{\max}), 0)$.
- 13: until the stopping criterion for the inner loop is fulfilled.
- 14: Evaluate $\rho^k := [f_\gamma(u^k) - f_\gamma(u^k + d^k)] / [f_\gamma(u^k) - (f_\gamma(u^k) + (g^k)^\top d^k + \frac{1}{2}(d^k)^\top H_{+, \varepsilon}^k d^k)]$.
- 15: if $\rho^k < \rho_1$ then Set $\sigma^{k+1} := \kappa_1 \sigma^k$.
- 16: else if $\rho^k > \rho_2$ then Set $\sigma^{k+1} := \kappa_2 \sigma^k$.
- 17: else $\sigma^{k+1} := \sigma^k$.
- 18: end if
- 19: Determine step size a^k along d^k such that $u^{k+1} = u^k + a^k d^k$ satisfies the Wolfe–Powell conditions: (WP1) $f_\gamma(u^{k+1}) \leq f_\gamma(u^k) + \tau_1 a^k \nabla f_\gamma(u^k)^\top d^k$ and (WP2) $\nabla f_\gamma(u^{k+1})^\top d^k \geq \tau_2 \nabla f_\gamma(u^k)^\top d^k$.
- 20: Set $\delta u^{k+1} := d^k$ and compute $\delta \bar{p}^{k+1}$ via (3.9). Update $u^{k+1} := u^k + a^k \delta u^{k+1}$ and $\bar{p}^{k+1} := \bar{p}^k + a^k \delta \bar{p}^{k+1}$.
- 21: Set $\beta^{k+1} := \beta^k$ and $k := k + 1$.
- 22: until the stopping criterion for the outer loop is fulfilled.

Teorema (Convergencia global)

Sea $u^{k+1} = u^k + \alpha^k d^k$ tal que las condiciones de Wolfe-Powell (WP1) y (WP2) se satisfacen. Entonces

$$\lim_{k \rightarrow \infty} \nabla \|f_\gamma(u^k)\| = 0.$$

Interpretación

El algoritmo no necesariamente encuentra un mínimo global, porque el problema es no convexo, pero sí converge hacia un punto estacionario del problema Huberizado.

Teorema (Convergencia local)

Sea (d^k) generada por el Algoritmo, y sea la sucesión $(u^k, \bar{p}^k)$ convergente a algún $(u^*, \bar{p}^*)$ que satisface el sistema de Euler-Lagrange (6). Supongamos que todos los elementos en $\partial_B^2 f_\gamma(u^*)$ son estrictamente definidos positivos. Entonces el Algoritmo es localmente superlinealmente convergente, es decir, para k suficientemente grande tenemos que

$$\|u^{k+1} - u^*\| = o\left(\|u^k - u^*\|\right) \quad \text{para } k \rightarrow \infty.$$

Notación

$\partial_B^2 f_\gamma(u)$ es el conjunto formado por todas las matrices en $\mathbb{R}^{|\Omega| \times |\Omega|}$ que son límites de sucesiones de la forma $\nabla^2 f_\gamma(u^k)$ con $u^k \rightarrow u$ y ∇f_γ diferenciable en u^k , es decir,

$$\partial_B^2 f_\gamma(u) := \{\lim \nabla^2 f_\gamma(u^k) : u^k \rightarrow u, \nabla f_\gamma \text{ es diferenciable en } u^k\}.$$

Además, $\nabla_B^2 f_\gamma(u)$ corresponde al B-Hessiano de f en u .

Los autores muestran los resultados obtenidos con su método de Newton primal-dual. En los cuales Ω denota el dominio de píxeles de tamaño $m \times n$, es decir,

$$\Omega = \{(i, j) \in \mathbb{Z}^2 : 1 \leq i \leq m, 1 \leq j \leq n\}.$$

Además, se discretiza el operador gradiente mediante

$$(\nabla u)_{i,j} = \left(\frac{u_{i+1,j} - u_{i,j}}{\omega}, \frac{u_{i,j+1} - u_{i,j}}{\omega} \right)$$

con $\omega = \sqrt{1/|\Omega|}$. Se fija $u_{i,j} = 0$ siempre que $(i, j) \notin \Omega$. A menos que se especifique lo contrario.

Imagen de los dos círculos. En este experimento el tamaño de la imagen es de 64×64 píxeles, la imagen original se contamina con ruido gaussiano de media cero y desviación estándar 0.1. Para este ejemplo $\alpha = 2 \times 10^{-3}$ y $\mu = 0$.

Dependencia del punto inicial

Punto inicial	Función objetivo	PSNR	CPU (seg)
$u^0 = z$	42.0354	30.2395	3.06
$u^0 = 0$	42.0385	30.2438	3.02
Random u^0	42.0373	30.2048	3.19

Dependencia del valor del parámetro de regularización (Parámetro de Huber)


Parámetro de Huber γ	1e1	1e0	1e-1	1e-2	1e-3
# Newton iter.	5	28	37	40	43
PSNR	25.3644	29.7011	30.12	30.1489	30.1489

Observación.

Vemos que conforme el valor del parámetro de Huber disminuye, el costo computacional (iteraciones) aumenta.



(a) Original image.



(b) Degraded image.

Figure 1. “Two circles” image.



(a) $u^0 = z$.



(b) $u^0 = 0$.



(c) Randomly chosen u^0 .

Figure 2. Dependence on initial guess.

Imagen Shepp-Logan phantom En este experimento el tamaño de la imagen es de 256×256 píxeles, la imagen original se contamina con ruido gaussiano de media cero y desviación estándar 0.05. Para este ejemplo $\mu = 0$. En este experimento se resuelve el problema para $q = 1, 0,75, 0,5$ y $0,25$. Para cada q , el parámetro α se escoge manualmente de modo que se obtenga el mejor valor de PSNR.

q	α
1	3×10^{-4}
0.75	4×10^{-4}
0.5	6×10^{-4}
0.25	1.2×10^{-3}

q	PSNR	$ \mathcal{A}_\gamma(\hat{u}_q) / \Omega $	$f_{\gamma,q}(\hat{u}_q)$	$f_{\gamma,q}(\hat{u}_1)$
1	37.5709	0.196	—	—
0.75	41.0039	0.0578	134.3021	137.6719
0.5	41.0191	0.0531	116.6721	125.6655
0.25	39.9259	0.0503	113.9953	133.6758

Observación.

- $\hat{u}_q$ es la imagen obtenida con el modelo TV_q.
- $\hat{u}_1$ es la imagen obtenida con el modelo TV.
- $|\mathcal{A}_\gamma(\hat{u}_q)|/|\Omega|$ mide la dispersión del gradiente.




Figure 6. Restoration via TV^q -models. In each group, the left figure is the restored image $\hat{u}_q$, and the right figure is the rescaled zoom-in of the restored image on the dash-boxed region of Figure 5(a).

- 1 Introduce un modelo TV_q no convexo para restauración de imágenes.
- 2 Prueba existencia de minimizador en el caso discreto.
- 3 Regulariza localmente el término no diferenciable mediante una función tipo Huber.
- 4 Propone un método Newton primal-dual semismooth.
- 5 Usa regularización basada en región de confianza para tratar Hessianos indefinidos.
- 6 Demuestra convergencia global y convergencia local superlineal hacia puntos estacionarios del problema regularizado.

M. Hintermüller y T. Wu (2013). *Nonconvex TV_q -Models in Image Restoration: Analysis and a Trust-Region Regularization-Based Superlinearly Convergent Solver*. SIAM Journal on Imaging Sciences, 6(3), 1385–1415.