

Seminarios

Daniela Riera

Centro de Modelización Matemática (MODEMAT)

mayo 2026



Índice

Introducción

Tratamiento del Problema

Algoritmo DC Primal-Dual

Conclusiones

Motivación y Formulación del Problema

Consideremos el problema de optimización **no convexo**:

$$(P) \quad \min_u \frac{1}{2} \|u - y\|^2 + \beta \sum_{i=1}^m \|(\mathbb{K}u)_i\|^q,$$

donde $u \in \mathbb{R}^n$, $q \in (0, 1)$, $\beta > 0$, y es la imagen contaminada con ruido, $\mathbb{K} : \mathbb{R}^n \rightarrow \mathbb{R}^{2m}$ es el gradiente discreto (con respecto a las direcciones x e y), es decir,

$$(\mathbb{K}u) = (\mathbb{K}_x u, \mathbb{K}_y u),$$

donde $\mathbb{K}_x : \mathbb{R}^n \rightarrow \mathbb{R}^m$ y $\mathbb{K}_y : \mathbb{R}^n \rightarrow \mathbb{R}^m$ corresponden a las derivadas parciales en la dirección horizontal y vertical, respectivamente.

Motivación y Formulación del Problema

Para cada $i = 1, \dots, m$

$$\|(\mathbb{K}u)_i\| = \|(\mathbb{K}_x^i u, \mathbb{K}_y^i u)\| = \left\| \begin{pmatrix} \mathbb{K}_x^i \\ \mathbb{K}_y^i \end{pmatrix} u \right\| = \|\mathbb{K}_i u\|,$$

donde $\mathbb{K}_x^i$ y $\mathbb{K}_y^i$ corresponden a la i -ésima fila de K_x y K_y , respectivamente.

Motivación y Formulación del Problema

La incorporación de la penalización TVq

$$\sum_{i=1}^m \|(\mathbb{K}u)_i\|^q$$

ayuda preservar de mejor manera los bordes presentes en la imagen y reducir el efecto de escalonamiento (staircasing effect) que es común cuando se utiliza la variación total (TV).

Tratamiento del Problema

El problema (P) es **no convexo** y **no diferenciable**, por lo que introducimos una regularización de tipo Huber. Para $\gamma \gg 1$ definimos

$$h_{q,\gamma}(t) = \begin{cases} q\gamma^{\frac{1-q}{q}} |t|^{\frac{1}{q}} & |t| \leq \frac{1}{\gamma}, \\ |t| + \frac{q-1}{\gamma} & |t| > \frac{1}{\gamma}. \end{cases}$$

La regularización $h_{p,\gamma}$ (donde $p = 1/q$) está definida en Merino, P. (2019). A difference-of-convex functions approach for sparse PDE optimal control problems with nonconvex costs. *Computational Optimization and Applications*, 74(1), 225-258.

Tratamiento del Problema

Luego,

$$(h_{q,\gamma}(t))^q = \begin{cases} \delta_\gamma |t|, & |t| \leq \frac{1}{\gamma}, \\ (|t| + (q-1)/\gamma)^q, & |t| > \frac{1}{\gamma}, \end{cases}$$

donde $\delta_\gamma := q^q \gamma^{1-q}$.

Tratamiento del Problema

De este modo, el problema (P) es aproximado por el problema parametrizado por γ :

$$(P_\gamma) \quad \min_u \frac{1}{2} \|u - y\|^2 + \beta \sum_{i=1}^m (h_{q,\gamma}(\|(\mathbb{K}u)_i\|))^q.$$

Condiciones de Optimalidad

Reformulamos (P_γ) como la minimización de la diferencia de dos funciones convexas: G y H .

$$G : \mathbb{R}^n \rightarrow \mathbb{R}$$

$$u \mapsto \frac{1}{2} \|u - y\|^2 + \delta_\gamma \beta \sum_{i=1}^m \|(\mathbb{K}u)_i\|,$$

$$H : \mathbb{R}^n \rightarrow \mathbb{R}$$

$$u \mapsto \beta \left(\sum_{i=1}^m [\delta_\gamma \|(\mathbb{K}u)_i\| - (h_{q,\gamma}(\|(\mathbb{K}u)_i\|))^q] \right).$$

Es decir, (P_γ) es equivalente a

$$\min_u G(u) - H(u).$$

Condiciones de Optimalidad

La función $j : \mathbb{R}_+ \cup \{0\} \rightarrow \mathbb{R}_+ \cup \{0\}$, definida por

$$j(t) = \begin{cases} \beta \delta_\gamma t - \beta \left(t + \frac{q-1}{\gamma} \right)^q & t > \frac{1}{\gamma}, \\ 0 & t \leq \frac{1}{\gamma} \end{cases}$$

es no negativa, convexa, continuamente diferenciable y su derivada está dada por

$$j'(t) = \begin{cases} \beta \delta_\gamma - \beta q \left(t + \frac{q-1}{\gamma} \right)^{q-1} & t > \frac{1}{\gamma}, \\ 0 & t \leq \frac{1}{\gamma}. \end{cases}$$

Condiciones de Optimalidad

Usando la función j , podemos escribir H como sigue:

$$H : \mathbb{R}^n \rightarrow \mathbb{R}$$
$$u \mapsto \sum_{i=1}^m j(\|(\mathbb{K}u)_i\|).$$

Condiciones de Optimalidad

Las funciones G y H son convexas.

$$G : \mathbb{R}^n \rightarrow \mathbb{R}$$

$$u \mapsto \frac{1}{2} \|u - y\|^2 + \delta_\gamma \beta \sum_{i=1}^m \|(\mathbb{K}u)_i\|,$$

$$H : \mathbb{R}^n \rightarrow \mathbb{R}$$

$$u \mapsto \sum_{i=1}^m j(\|(\mathbb{K}u)_i\|).$$

En efecto, puesto que $\frac{1}{2} \|\cdot\|^2$ es estrictamente convexa, $\delta_\gamma \beta > 0$, $\|\cdot\|$ es convexa y la suma preserva la convexidad, por tanto G es estrictamente convexa. Dado que j es convexa, H es convexa.

Condiciones de Optimalidad

Usando la programación DC (difference of convex functions), tenemos que si u^* es un mínimo local para (P_γ) , entonces u^* satisface la condición de criticalidad:

$$\partial H(u^*) \subset \partial G(u^*),$$

donde ∂H y ∂G corresponden a los subdiferenciales de H y G , respectivamente.

Condiciones de Optimalidad

La función H es Gâteaux diferenciable y su derivada es

$$\nabla H(u) = \mathbb{K}^T w,$$

donde $w = D_a \mathbb{K}u \in \mathbb{R}^{2m}$, $D_a = \text{diag}(a_1, a_2, \dots, a_m, a_1, a_2, \dots, a_m)$ es una matriz diagonal en $\mathbb{R}^{2m \times 2m}$,

$$a_i = \hat{j}(\|(\mathbb{K}u)_i\|) = \begin{cases} \frac{j'(\|(\mathbb{K}u)_i\|)}{\|(\mathbb{K}u)_i\|} & \|(\mathbb{K}u)_i\| > \frac{1}{\gamma}, \\ 0 & \|(\mathbb{K}u)_i\| \leq \frac{1}{\gamma}. \end{cases}$$

y

$$\mathbb{K}u = [\mathbb{K}_x^1 u, \dots, \mathbb{K}_x^m u, \mathbb{K}_y^1 u, \dots, \mathbb{K}_y^m u]^T \in \mathbb{R}^{2m}.$$

Condiciones de Optimalidad

Si u^* es una solución de (P_γ) , entonces u^* satisface el siguiente sistema de optimalidad:

$$\mathbb{K}^T w - u^* + y - \delta_\gamma \sum_{i=1}^m \mathbb{K}_i^T z_i = 0,$$

$$z_i \in \beta \partial \|\cdot\|((\mathbb{K}u^*)_i), \quad \forall i = 1, \dots, m.$$

Condiciones de Optimalidad

Idea de la demostración.

- Tomamos u^* una solución de (P_γ) .
- Calculamos $\partial G(u^*) = \left\{ u^* - y + \delta_\gamma \sum_{i=1}^m \mathbb{K}_i^T z_i \right\}$, donde

$$z_i \in \beta \partial \| \cdot \|((\mathbb{K}u^*)_i) = \begin{cases} \frac{\beta(\mathbb{K}u)_i}{\|(\mathbb{K}u)_i\|} & (\mathbb{K}u)_i \neq 0, \\ \beta \text{cl} B_*(0, 1) & (\mathbb{K}u)_i = 0. \end{cases}$$

- Tomamos $h \in \partial H(u^*) = \{\nabla H(u^*)\}$, así $h = \mathbb{K}^T w$. De la condición de criticalidad $(\partial H(u^*) \subset \partial G(u^*))$, $h \in \partial G(u^*)$.

Condiciones de Optimalidad

- Como $h \in \partial G(u^*)$,

$$h = u^* - y + \delta_\gamma \sum_{i=1}^m \mathbb{K}_i^T z_i.$$

- Finalmente,

$$\mathbb{K}^T w = u^* - y + \delta_\gamma \sum_{i=1}^m \mathbb{K}_i^T z_i,$$

$$\Rightarrow \mathbb{K}^T w - u^* + y - \delta_\gamma \sum_{i=1}^m \mathbb{K}_i^T z_i = 0.$$

Algoritmo DC Primal-Dual

Para resolver numéricamente el problema (P_γ) proponemos combinar el DCA - Primal-Dual Hybrid Gradient:

1. Choose $\sigma > 0, \tau > 0, \theta, q, \gamma$
2. Initialize $u_0, \bar{u}_0, y_0$; set $k = 0$
3. **repeat** Until DC stopping criteria is satisfied
4. Compute $\mathbb{K}^T w_k \in \partial H(u_k)$
5. Compute
$$u_k \in \partial G^*(\mathbb{K}^T w_k) = \operatorname{argmin}_{u_k} \{G(u_k) - \langle \mathbb{K}^T w_k, u_k \rangle\}$$
6. **end**

Algoritmo DC Primal-Dual

Notemos que el paso 5 es equivalente a resolver el siguiente problema:

$$\min_{u_k} -\langle \mathbb{K}^T w_k, u_k \rangle + \frac{1}{2} \|u_k - y\|^2 + \delta_\gamma \beta \sum_{i=1}^m \|(\mathbb{K} u_k)_i\|.$$

El cual es equivalente a

$$\min_{u_k} -\frac{1}{\beta \delta_\gamma} \langle \mathbb{K}^T w_k, u_k \rangle + \frac{1}{2 \delta_\gamma \beta} \|u_k - y\|^2 + \sum_{i=1}^m \|(\mathbb{K} u_k)_i\|.$$

Algoritmo DC Primal-Dual

Tomando

$$F(u_k) := \frac{1}{2\beta\delta_\gamma} \|u_k - y\|^2 - \frac{1}{\delta_\gamma\beta} \langle \mathbb{K}^T w_k, u_k \rangle \text{ y } G(\mathbb{K}u) := \|\mathbb{K}u\|_1,$$

donde $\|\mathbb{K}u\|_1 = \sum_{i=1}^m \|(\mathbb{K}u)_i\|$, obtenemos el siguiente problema

$$\min_{u_k} F(u_k) + G(\mathbb{K}u_k).$$

Algoritmo DC Primal-Dual

Para resolverlo, usamos el algoritmo Primal Dual Hybrid Gradient (PDHG) para resolver el paso 5:

5.1 **while** Until stopping criteria is satisfied **do**

5.2 $p_{k+1} = \text{prox}_{\sigma G^*}(p^k + \sigma \mathbb{K} \bar{u}_k)$

5.3 $u_{k+1} = \text{prox}_{\tau F}(u^k - \tau \mathbb{K}^* p^k)$

5.4 $\bar{u}_{k+1} = u_{k+1} + \theta(u_{k+1} - u_k)$

5.5 **end**

Experimentación Numérica

¿Qué sucede si aumentamos el valor de β ?



Imagen Original



Imagen con ruido, PSNR = 22.35, SSIM = 0.48



$q = 0.99$, $\beta = 0.08$, PSNR = 25.70, SSIM = 0.77



TV, $\beta = 0.08$, PSNR = 25.73, SSIM = 0.77

Conclusiones y Trabajo en Progreso

- La elección de los parámetros q y β influye de manera determinante en la calidad de los resultados y en el costo computacional. Es por ello que planteamos un **problema binivel**, que nos permita encontrar el valor de β óptimo. Puesto que, los experimentos numéricos muestran un valor grande de β , pueden causar un sobre suavizado de la imagen.

$$(PB_\gamma) \begin{cases} \min_{(u,\beta) \in \mathbb{R}^n \times \mathbb{R}_+} J(u) \\ \text{sujeto a} \\ \left\{ \min_u \frac{1}{2} \|u - y\|^2 + \beta \sum_{i=1}^m h_{q,\gamma}(\|(\mathbb{K}u)_i\|)^q. \right. \end{cases}$$

- Una vez planteado el problema Binivel, se demostrarán condiciones de calificación particulares y se resolverá numéricamente utilizando un algoritmo de punto interior.