

Modelos TV^q no convexos en Restauración de Imágenes
análisis y un solucionador basado en regularización de región de confianza con
convergencia superlineal

Hintermüller y Wu (2013)

MODEMAT

28 de mayo de 2026

Estructura y Agenda de la Charla

Parte I: Fundamentos y Modelo

- 1. El Problema Inverso en Imágenes
- 2. Limitaciones de los Modelos Convexos (ℓ_1)
- 3. Ventajas de la No Convexidad (ℓ_q)
- 4. Definición del Funcional TV^q
- 5. Propiedades del Espacio Discreto

Parte II: Análisis del Funcional

- 6. Coercividad y Teorema de Existencia
- 7. No Suavidad en el Origen
- 8. El Operador de Regularización de Huber
- 9. Consistencia y Límite cuando $\gamma \rightarrow 0$

Parte III: Algoritmo y Solución

- 11. Formulación Primal-Dual
- 12. Diferenciabilidad Semismooth (Slanted)
- 13. Construcción del B-Hessiano
- 14. Indefinición del Hessiano No Convexo
- 15. Regularización R Adaptativa
- 16. Dinámica del Radio de Trust-Region
- 17. Búsqueda Lineal de Wolfe-Powell
- 18. El Algoritmo Completo SSN-TR

Parte IV: Convergencia y Numérica

- 19. Teorema de Convergencia Global

Introducción

Objetivo principal del artículo:

- Expandir la capacidad de los algoritmos para recuperar imágenes usando la norma ℓ_q .
- Lograr robustez ante el ruido y convergencia superlineal local.

Problema Inverso en Restauración de Imágenes

Se considera el siguiente problema variacional

$$\min_{u \in \mathbb{R}^{|\Omega|}} f(u) := \sum_{(i,j) \in \Omega} \left[\frac{\mu}{2} |(\nabla u)_{ij}|^2 + \frac{\alpha}{q} |(\nabla u)_{ij}|^q + \frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2 \right], \quad (1)$$

donde:

- Ω representa el dominio de la imagen y $|\Omega|$ denota su cardinalidad.
- $\alpha > 0$, $q \in (0, 1)$, $0 < \mu \ll \alpha$ son los parámetros del modelo.
- El vector $z \in \mathbb{R}^{|\Omega|}$ representa la imagen dañada, mientras que $u \in \mathbb{R}^{|\Omega|}$ es la imagen reconstruida.
- $K \in \mathbb{R}^{|\Omega| \times |\Omega|}$ es una matriz que no anula al vector constante (por ejemplo, la matriz de desenfoque). $|(\nabla u)_{ij}|$ corresponde a la norma euclidiana de $(\nabla u)_{ij} \in \mathbb{R}^2$.
- $\lambda_{ij} > 0 \in \mathbb{R}^{|\Omega|}$ es el coeficiente de fidelidad y ∇ es el operador gradiente discreto $\nabla = (\nabla_x \nabla_y)$.

Existencia de solución

Teorema 1

Supongamos que $\mu \geq 0$, $\alpha > 0$, $q > 0$, $\lambda_{ij} > 0$ para todo $(i, j) \in \Omega$ y

$$\text{Ker} \nabla \cap \text{Ker} K = \{0\}.$$

Entonces existe un minimizador global para el problema variacional (1).

Idea de la Demostración:

- 1 Dado que f es acotada inferiormente, basta probar que f es coerciva (tiende a $+\infty$ cuando $\|u\|$ tiende a $+\infty$), puesto que si f es coerciva y continua, entonces existe un minimizador.
- 2 La coercividad de f se prueba por contradicción, de modo que se encuentra un elemento no nulo en la intersección de $\text{Ker}(\nabla)$ y $\text{Ker}(K)$. Como esto no es posible de acuerdo a la hipótesis, entonces f es coerciva.

Existencia de solución

Para caracterizar la solución óptima u , se definen los conjuntos activo e inactivo de la siguiente forma:

$$\mathcal{A}(u) := \{(i, j) \in \Omega : |(\nabla u)_{ij}| \neq 0\}, \quad \mathcal{I}(u) := \Omega \setminus \mathcal{A}(u).$$

Como f es no diferenciable en $\mathcal{I}(u)$, la ecuación de Euler-Lagrange para caracterizar un punto estacionario se plantea como sigue

$$\begin{cases} -\mu \Delta u + K^T \lambda (Ku - z) + \alpha \nabla^T (|\nabla u|^{q-2} \nabla u) = 0 & \text{si } (i, j) \in \mathcal{A}(u) \\ \nabla u = 0 & \text{si } (i, j) \in \mathcal{I}(u). \end{cases} \quad (2)$$


Dado que f no es convexa, la solución de (2) en general no es única.

Regularización del término TV^q

Regularización mediante una función de Huber φ_γ :

$$\varphi_\gamma(s) = \begin{cases} \frac{1}{q}|s|^q - \left(\frac{1}{q} - \frac{1}{2}\right)\gamma^q & \text{si } |s| > \gamma, \\ \frac{1}{2}\gamma^{q-2}|s|^2 & \text{si } |s| \leq \gamma, \end{cases}$$

con $\gamma > 0$ pequeño.



Regularización del término TV^q

De este modo obtenemos el problema regularizado que aproxima al problema original, dado de la siguiente forma

$$\min_{u \in \mathbb{R}^{|\Omega|}} f_\gamma(u) := \sum_{(i,j) \in \Omega} \left(\frac{\mu}{2} |(\nabla u)_{ij}|^2 + \alpha \varphi_\gamma(|(\nabla u)_{ij}|) + \frac{\lambda_{ij}}{2} |(Ku - z)_{ij}|^2 \right). \quad (3)$$

Dado que f_γ es continuamente diferenciable, la ecuación de Euler-Lagrange está dada por

$$\nabla f_\gamma(u) = -\mu \Delta u + \mathbb{K}^T \lambda(Ku - z) + \alpha \nabla^T (\text{máx}(|\nabla u|, \gamma)^{q-2} \nabla) \quad (4)$$

Regularización del término TV^q

¿Qué sucede si $\gamma \rightarrow 0^+$?

Theorem (Teorema 2)

Sean válidos los supuestos del Teorema 1. Además supongamos que (u^k) es una sucesión uniformemente acotada, donde cada u^k es un punto estacionario del problema (3) que satisface (4). Entonces cuando $\gamma \rightarrow 0^+$, existe una subsucesión de (u^k) que converge a algún $u^ \in \mathbb{R}^{|\Omega|}$, el cual satisface la ecuación de Euler-Lagrange original (2)*

3. Motivación de la Regularización No Convexa ℓ_q

Para evitar el *staircasing*, la literatura moderna recurre a las pseudo-normas ℓ_q con $0 < q < 1$:

- Sparsity:** La penalización $|x|^q$ para $q < 1$ se aproxima fuertemente a la norma ℓ_0 (recuperación exacta de bordes).
- Preservación de Discontinuidades:** Castiga menos los saltos grandes y penaliza fuertemente las variaciones pequeñas cerca del origen.
- Precisión Matemática:** El modelo se adapta mejor a las estadísticas estadísticas reales de las imágenes naturales (distribuciones de cola pesada).

8. El Problema Analítico de la No Suavidad en el Origen

Analicemos la derivada de la función de costo respecto a la magnitud del gradiente $s = |\nabla u|$:

$$\frac{d}{ds} \left(\frac{\alpha}{q} s^q \right) = \alpha s^{q-1} = \frac{\alpha}{s^{1-q}} \quad (5)$$

Singularidad de la Primera Derivada

Como $0 < q < 1$, el exponente $1 - q > 0$. Por lo tanto, cuando el gradiente de la imagen se aproxima a cero ($s \rightarrow 0^+$), la derivada **tiende a infinito**:

$$\lim_{s \rightarrow 0^+} \alpha s^{q-1} = +\infty.$$

Esto bloquea la aplicación directa del método de Newton clásico, ya que el gradiente del funcional no está definido en los puntos uniformes de la imagen.

9. Técnica de Solución: Suavizado por Huberización Local

Para remover la singularidad en el origen sin destruir el comportamiento no convexo en los bordes, el paper introduce una vecindad de suavizado controlada por un radio pequeño $\gamma > 0$:

$$\phi_{\gamma}(s) = \begin{cases} \frac{1}{q}|s|^q - \left(\frac{1}{q} - \frac{1}{2}\right)\gamma^q & \text{si } |s| > \gamma \\ \frac{1}{2}\gamma^{q-2}|s|^2 & \text{si } |s| \leq \gamma \end{cases} \quad (6)$$

- **Continuidad C1:** La función de transición $\phi_{\gamma}(s)$ está diseñada para igualar tanto el valor de la función como su primera derivada en el punto de contacto crítico $|s| = \gamma$.
- En la zona inactiva ($|s| \leq \gamma$), el término se comporta como una regularización parabólica estándar bien definida.

10. Teorema de Consistencia Asintótica (Teorema 2.2)

Definimos el funcional aproximado regularizado como $f_\gamma(u)$. Es imperativo demostrar que optimizar f_γ es representativo del problema original.

Theorem (Consistencia)

Sea $\{\gamma_k\}_{k=1}^\infty$ una sucesión de parámetros positivos tales que $\lim_{k \rightarrow \infty} \gamma_k = 0$, y sea u^k un punto estacionario de f_{γ_k} . Entonces, toda secuencia acumulativa o punto límite u^ de la sucesión $\{u^k\}$ es un punto estacionario legítimo del funcional original $f(u)$.*

Esto justifica matemáticamente resolver el problema aproximado mediante una estrategia de continuación numérica reduciendo el valor de γ .

11. Condiciones de Optimalidad de Primer Orden del Problema Regularizado

El gradiente del funcional aproximado de Huber $f_\gamma(u)$ igualado a cero nos entrega el sistema de ecuaciones no lineales de Euler-Lagrange:

$$\nabla f_\gamma(u) = -\mu \Delta u + K^\top \Lambda(Ku - z) + \alpha \nabla^\top (\max(|\nabla u|, \gamma)^{q-2} \nabla u) = 0 \quad (7)$$

Donde:

- $\Delta = -\nabla^\top \nabla$ denota el operador Laplaciano discreto estándar.
- Λ es la matriz diagonal que contiene los pesos locales de fidelidad λ_{ij} .

12. Formulación Primal-Dual Equivalente

Para estabilizar la fuerte no linealidad, se introduce una variable dual artificial acoplada $\vec{p} \in \mathbb{R}^{2|\Omega|}$ que captura la dirección del gradiente normalizado:

$$\vec{p} = \max(|\nabla u|, \gamma)^{q-2} \nabla u \quad (8)$$

Despejando y reordenando los términos, obtenemos el sistema primal-dual equivalente de raíces:

$$-\mu \Delta u + K^\top \Lambda(Ku - z) + \alpha \nabla^\top \vec{p} = 0 \quad (9)$$

$$\max(|\nabla u|, \gamma)^{2-q} \vec{p} - \nabla u = 0 \quad (10)$$

13. Diferenciabilidad Semismooth (Slanted Differentiability)

El término $\max(|\nabla u|, \gamma)$ no es diferenciable en el sentido clásico de Fréchet debido al cambio abrupto de pendiente en el punto de corte γ .

Definición de Operador Semismooth

Un mapeo no lineal G es semismooth en x si existe un mapeo superidéntico generalizado G° tal que:

$$\lim_{h \rightarrow 0} \frac{\| G(x+h) - G(x) - G^\circ(x+h)h \|}{\| h \|} = 0 \quad (11)$$

La teoría analítica de espacios modernos demuestra que las funciones de tipo máximo/mínimo euclidianas son semismooth, abriendo las puertas al cálculo del Newton generalizado.

14. Construcción Estructural del B-Hessiano

Aplicando la diferenciación generalizada de Bouligand al sistema primal-dual en la iteración k , la matriz de iteración de Newton $J(u^k, \vec{p}^k)$ toma la forma de bloques:

$$J(u^k, \vec{p}^k) = \begin{pmatrix} -\mu\Delta + K^\top \Lambda K & \alpha \nabla^\top \\ -B^k \nabla & A^k \end{pmatrix} \quad (12)$$

Donde las matrices diagonales operadoras A^k y B^k se evalúan según el estado local de los conjuntos activos e inactivos de la imagen:

- **Zonas Inactivas** ($|\nabla u| \leq \gamma$): El gradiente es pequeño, la aproximación es cuadrática.
- **Zonas Activas** ($|\nabla u| > \gamma$): Predomina el carácter no convexo del exponente fraccionario q .

15. Reducción al Sistema Schur Primal

Despejando la variable de actualización dual $\delta \vec{p}$ e inyectándola directamente en la primera ecuación lineal por bloques, el sistema completo se reduce a resolver una ecuación que involucra únicamente a la variable primal δu :

$$H^k \delta u = -g^k \quad (13)$$

Donde el operador B-Hessiano condensado primario H^k es:

$$H^k = -\mu \Delta + K^\top \Lambda K + \alpha \nabla^\top D^k \nabla \quad (14)$$

La matriz diagonal D^k actúa como un difusor anisotrópico generalizado dependiente de la iteración.

16. Análisis de la Indefinición del Hessiano No Convexo

Analicemos el valor explícito de la matriz de difusión diagonal D^k en las regiones activas donde $|\nabla u^k| > \gamma$:

$$D^k = |\nabla u^k|^{q-2} \left(I - (2 - q) \frac{\nabla u^k (\nabla u^k)^\top}{|\nabla u^k|^2} \right) \quad (15)$$

Valores Propios Negativos

El operador proyección posee un autovalor igual a $1 - (2 - q) = q - 1$. Como $q < 1$, este valor es **estrictamente negativo**! Por lo tanto, en zonas con transiciones abruptas, la matriz H^k pierde la propiedad de ser definida positiva, provocando direcciones de ascenso o estancamiento.

17. Regularización R Adaptativa

Para fuerza la estabilidad numérica sin perder la estructura física del operador diferencial, el paper introduce una modificación de tipo Levenberg-Marquardt / Trust-Region:

$$(H^k + \beta^k R^k) \delta u^k = -g^k \quad (16)$$

Donde:

- $R^k \in \mathbb{R}^{N \times N}$ es una matriz simétrica definida positiva elegida convenientemente como el operador elíptico estándar.
- $\beta^k \geq 0$ es el coeficiente escalar dinámico controlado por el radio de la Región de Confianza.

18. Control Dinámico mediante el Ratio de Descenso ρ^k

Tras calcular una dirección candidata δu^k , calculamos el coeficiente de fidelidad del modelo cuadrático ρ^k :

$$\rho^k = \frac{f_\gamma(u^k + \delta u^k) - f_\gamma(u^k)}{q^k(\delta u^k) - q^k(0)} \quad (17)$$

Donde $q^k(\cdot)$ representa la aproximación cuadrática local del funcional.

- **Si $\rho^k \geq 0,75$ (Excelente ajuste):** Se acepta el paso y se reduce la regularización para la siguiente iteración ($\beta^{k+1} = \beta^k/2$).
- **Si $\rho^k < 0,25$ (Mal ajuste):** Se rechaza el paso numérico y se incrementa fuertemente la penalización ($\beta^{k+1} = 2\beta^k$).

19. Búsqueda Lineal de Wolfe-Powell

Para garantizar que el algoritmo avance de forma estricta incluso en configuraciones altamente no convexas alejadas del óptimo, el paso aceptado se refina bajo las condiciones de Wolfe:

$$f_{\gamma}(u^k + \tau^k \delta u^k) \leq f_{\gamma}(u^k) + c_1 \tau^k \langle \nabla f_{\gamma}(u^k), \delta u^k \rangle \tag{18}$$

$$\langle \nabla f_{\gamma}(u^k + \tau^k \delta u^k), \delta u^k \rangle \geq c_2 \langle \nabla f_{\gamma}(u^k), \delta u^k \rangle \tag{19}$$

Con $0 < c_1 < c_2 < 1$. Esto evita pasos excesivamente cortos y asegura estabilidad global iterativa.

20. El Algoritmo Completo SSN-TR

Esquema Iterativo de Hintermüller & Wu

- ① Fijar parámetros $\mu, \alpha, \gamma > 0$, punto inicial u^0 , y regularización inicial $\beta^0 = 1$.
- ② **Mientras** $\|\nabla f_\gamma(u^k)\| > \text{Tolerancia}$:
 - ① Armar la matriz del B-Hessiano H^k y el residuo g^k .
 - ② Resolver el sistema lineal estabilizado: $(H^k + \beta^k R^k)\delta u = -g^k$.
 - ③ Calcular el ratio de confianza ρ^k .
 - ④ Actualizar el estado de aceptación del paso y actualizar β^{k+1} según las reglas de control.
 - ⑤ Encontrar el tamaño de paso óptimo τ^k usando Wolfe-Powell.
 - ⑥ Actualizar el vector de la imagen: $u^{k+1} = u^k + \tau^k \delta u^k$.

21. Demostración de la Convergencia Global (Teorema 3.7)

Theorem (Convergencia Global)

Sea u^k la secuencia generada por el algoritmo SSN-TR utilizando las condiciones de búsqueda lineal de Wolfe-Powell. Entonces, la secuencia de gradientes del funcional converge de forma asintótica al origen:

$$\lim_{k \rightarrow \infty} \|\nabla f_\gamma(u^k)\| = 0 \quad (20)$$

Esta propiedad provee robustez total frente a la elección aleatoria del punto de partida de la imagen (como ruido puro o imágenes negras).

22. Demostración de la Tasa Superlineal Local (Teorema 3.10)

La justificación fundamental de usar métodos basados en Newton en lugar de gradiente descendiente radica en la velocidad final del algoritmo:

Theorem (Convergencia Superlineal)

Supongamos que la secuencia u^k converge a un óptimo local estricto u^ donde el B-Hessiano límite sea fuertemente positivo definido ($H^* \succ 0$). Entonces el parámetro de la región de confianza decae a cero ($\beta^k \rightarrow 0$) y la secuencia exhibe convergencia superlineal:*

$$\lim_{k \rightarrow \infty} \frac{\|u^{k+1} - u^*\|}{\|u^k - u^*\|} = 0 \quad (21)$$

23. Experimentación Numérica I: Eliminación de Ruido (Denoising)

Se aplicó el algoritmo sobre imágenes estándar contaminadas con ruido Gaussiano severo ($\text{SNR} = 10\text{dB}$):

- **Modelos en comparación:** Método de punto fijo lineal (*Lagged Diffusivity*) vs. Quasi-Newton (BFGS) vs. Método Propuesto (SSN-TR).
- **Criterio de parada:** Reducción del residuo relativo por debajo de 10^{-7} .

Comportamiento Numérico

Mientras que BFGS requiere cientos de iteraciones debido al mal condicionamiento, el método propuesto converge de manera consistente en menos de 40 iteraciones generales.

24. Tabla Comparativa de Tiempos y Calidad Métrica

Cuadro: Métricas extraídas de la sección experimental del paper original

Algoritmo Evaluado	Iteraciones	Métrica PSNR (dB)	Tiempo CPU (s)
Quasi-Newton Estándar (BFGS)	> 300	28.41	32.15
Lagged-Diffusivity Fixed Point	43	30.10	20.02
Método Propuesto (SSN-TR)	37	30.15	3.07

25. Efecto Estructural del Exponente Fraccionario q

- **Caso $q = 1,0$ (Variación Total Clásica):** Genera pérdida de texturas finas y el característico efecto de parches artificiales rectos (*staircasing*).
- **Caso $q = 0,5$ (Óptimo Recomendado):** Produce transiciones de contraste perfectas. Los bordes de los objetos se recuperan con un grosor de un solo píxel, modelando fielmente las funciones continuas por tramos.
- **Caso $q \rightarrow 0,1$ (No Convexidad Extrema):** Promueve un contraste hiper-definido, pero vuelve el funcional extremadamente plano en los mínimos locales.

26. Aplicación Avanzada en Operadores Densos: Transformada de Radon

El paper expande las pruebas hacia la reconstrucción tomográfica, donde el operador K representa proyecciones angulares submuestreadas (Transformada de Radon):

- En este escenario, la matriz K es densa y de gran dimensión, imposibilitando su inversión directa.
- **Resolución:** El sistema lineal interno del método de Newton se resuelve mediante un subbucle del método de **Gradiente Conjugado** sin necesidad de almacenar la matriz en memoria explícitamente.

27. Formulación en Espacios de Dimensión Infinita

En la última sección del paper, los autores analizan el funcional en el espacio de Sóbolev continuo $H_0^1(\Omega)$:

$$\mathcal{E}(u) = \int_{\Omega} \left(\frac{\mu}{2} |\nabla u|^2 + \frac{\alpha}{q} |\nabla u|^q \right) dx + \frac{\lambda}{2} \|Ku - z\|_{L^2}^2 \quad (22)$$

Falla de la Semicontinuidad Inferior

Dado que el integrando $t \mapsto \frac{\mu}{2} t^2 + \frac{\alpha}{q} t^q$ es **no convexo**, el funcional completo pierde la propiedad de semicontinuidad inferior débil (*w.l.s.c.*). No se puede garantizar la existencia de soluciones sin aplicar técnicas de relajación variacional.

28. Relajación y la Envolvente Bipolar

Para estudiar el comportamiento límite, se construye la envolvente biconjugada o biconvexa del integrando (la mayor función convexa inferior minorante):

- El problema relajado sí posee soluciones estables garantizadas en el espacio de funciones.
- Los autores demuestran el llamado **Efecto Bolza**, donde el ínfimo del problema original coincide con el mínimo del problema relajado.

29. Conclusiones y El Gran Aporte del Paper

Este trabajo marcó un hito en el procesamiento de imágenes y la optimización numérica por tres razones fundamentales:

- ➊ **Ruptura del Parafígma Lineal:** Demostró que los problemas no convexos no lineales no suaves pueden ser resueltos con la misma velocidad (o superior) que los modelos convexos clásicos si se explota adecuadamente la estructura matemática del Hessiano generalizado.
- ➋ **Arquitectura Robusta:** El acoplamiento de la regularización Trust-Region con métodos Newton Semismooth primal-duales se convirtió en un estándar de diseño para solvers en problemas inversos modernos.

¿Preguntas?

Muchas gracias por su atención en esta sesión técnica.

Maestría en Optimización Matemática

Universidad de Investigación - Ingeniería Matemática

Referencia: M. Hintermüller, T. Wu. *Nonconvex TV-Models in Image Restoration*, SIAM J. Imaging Sciences, 2013.